

# Tarea 1 Modelos Lineales

Pablo Borrego Ramos

Marzo 2024

## 1

### 1.1 Enunciado

Supongamos que  $\mathbf{Y}$  se ajusta a un modelo lineal básico de rango completo, es decir,  $E[\mathbf{Y}] = \mathbf{X}\beta$  y  $Cov[\mathbf{Y}] = \sigma^2 I_n$  siendo  $\mathbf{X}$  una matriz de orden  $n \times p$  con  $p < n$  y  $r(\mathbf{X}) = p$ . Supongamos que escribimos  $\mathbf{X}\beta = \mathbf{X}_1\delta_1 + \mathbf{X}_2\delta_2$  donde  $\delta_1 \in \mathbb{R}^r$  y  $\delta_2 \in \mathbb{R}^{p-r}$ ,  $\mathbf{X}_1$  es una matriz  $n \times r$  y  $\mathbf{X}_2$  es una matriz  $n \times (p-r)$ . Probar que  $\hat{\delta}_1 = (\mathbf{X}_1^t \mathbf{X}_1)^{-1} \mathbf{X}_1^t \mathbf{X}$  y  $\hat{\delta}_2 = (\mathbf{X}_2^t \mathbf{X}_2)^{-1} \mathbf{X}_2^t \mathbf{X}$  son estimadores insesgados para  $\delta_1$  y  $\delta_2$  respectivamente si y solo si  $\mathbf{X}_1^t \mathbf{X}_2 = 0$ , en cuyo caso  $Cov[\hat{\delta}_1, \hat{\delta}_2] = 0$

### 1.2 Respuesta

$\Rightarrow$

Si  $E[\hat{\delta}_1] = \delta_1$  entonces  $(\mathbf{X}_1^t \mathbf{X}_1)^{-1} \mathbf{X}_1^t E[\mathbf{Y}] = \delta_1$  simplificando la parte izquierda de la igualdad llegamos a que  $(\mathbf{X}_1^t \mathbf{X}_1)^{-1} \mathbf{X}_1^t \mathbf{X}\beta = (\mathbf{X}_1^t \mathbf{X}_1)^{-1} \mathbf{X}_1^t (\mathbf{X}_1\delta_1 + \mathbf{X}_2\delta_2) = (\mathbf{X}_1^t \mathbf{X}_1)^{-1} (\mathbf{X}_1^t \mathbf{X}_1)\delta_1 + (\mathbf{X}_1^t \mathbf{X}_1)^{-1} (\mathbf{X}_1^t \mathbf{X}_2)\delta_2 = \mathbf{I}_r\delta_1 + (\mathbf{X}_1^t \mathbf{X}_1)^{-1} (\mathbf{X}_1^t \mathbf{X}_2)\delta_2 = \delta_1$  realizando un procedimiento similar con la igualdad  $E[\hat{\delta}_2] = \delta_2$  obtenemos  $\mathbf{I}_{p-r}\delta_2 + (\mathbf{X}_2^t \mathbf{X}_2)^{-1} (\mathbf{X}_2^t \mathbf{X}_1)\delta_1 = \delta_2$  llegando a un sistema de ecuaciones de la forma:

$$(\mathbf{X}_1^t \mathbf{X}_1)^{-1} (\mathbf{X}_1^t \mathbf{X}_2)\delta_1 = 0$$

$$(\mathbf{X}_2^t \mathbf{X}_2)^{-1} (\mathbf{X}_2^t \mathbf{X}_1)\delta_1 = 0$$

Como  $r(\mathbf{X}) = p$  entonces  $\mathbf{X}_1$  o  $\mathbf{X}_2$  debe de ser de rango máximo, y por lo tanto  $(\mathbf{X}_1^t \mathbf{X}_1)^{-1}$  o  $(\mathbf{X}_2^t \mathbf{X}_2)^{-1}$  es no nulo, por lo tanto para que se cumpla el sistema de ecuaciones debe de ocurrir que  $(\mathbf{X}_1^t \mathbf{X}_2) = 0$  o  $(\mathbf{X}_2^t \mathbf{X}_1) = 0$  en el primer caso ya habríamos terminado, en el segundo si  $(\mathbf{X}_2^t \mathbf{X}_1) = 0$  entonces  $(\mathbf{X}_2^t \mathbf{X}_1)^t = (\mathbf{X}_1^t \mathbf{X}_2) = 0$ . Ahora veamos que  $Cov[\hat{\delta}_1, \hat{\delta}_2] = 0$ :

$$Cov[\hat{\delta}_1, \hat{\delta}_2] = Cov[(\mathbf{X}_1^t \mathbf{X}_1)^{-1} \mathbf{X}_1^t \mathbf{X}, (\mathbf{X}_2^t \mathbf{X}_2)^{-1} \mathbf{X}_2^t \mathbf{X}] = (\mathbf{X}_1^t \mathbf{X}_1)^{-1} \mathbf{X}_1^t Cov[\mathbf{X}, \mathbf{X}] \mathbf{X}_2 ((\mathbf{X}_2^t \mathbf{X}_2)^{-1})^t =$$

$(\mathbf{X}_1^t \mathbf{X}_1)^{-1} \mathbf{X}_1^t \sigma^2 \mathbf{I}_n \mathbf{X}_2 ((\mathbf{X}_2^t \mathbf{X}_2)^{-1})^t = \sigma^2 (\mathbf{X}_1^t \mathbf{X}_1)^{-1} \mathbf{X}_1^t 0_n \mathbf{X}_2 ((\mathbf{X}_2^t \mathbf{X}_2)^{-1})^t = 0$  donde la penúltima igualdad se debe a que  $(\mathbf{X}_1^t \mathbf{X}_2) = 0$

$\Leftarrow$

Si  $(\mathbf{X}_1^t \mathbf{X}_2) = 0$  veamos que  $E[\hat{\delta}_1] = \delta_1$ :  
 $E[\hat{\delta}_1] = (\mathbf{X}_1^t \mathbf{X}_1)^{-1} \mathbf{X}_1^t \mathbf{X} E[\mathbf{Y}] = (\mathbf{X}_1^t \mathbf{X}_1)^{-1} \mathbf{X}_1^t \mathbf{X} \beta = (\mathbf{X}_1^t \mathbf{X}_1)^{-1} \mathbf{X}_1^t (\mathbf{X}_1 \delta_1 + \mathbf{X}_2 \delta_2) =$   
 $(\mathbf{X}_1^t \mathbf{X}_1)^{-1} (\mathbf{X}_1^t \mathbf{X}_1) \delta_1 + (\mathbf{X}_1^t \mathbf{X}_1)^{-1} (\mathbf{X}_1^t \mathbf{X}_2) \delta_2 = \mathbf{I}_r \delta_1 + (\mathbf{X}_1^t \mathbf{X}_1)^{-1} (\mathbf{X}_1^t \mathbf{X}_2) \delta_2 =$   
 $\mathbf{I}_r \delta_1 + 0_{p-r} \delta_2 = \delta_1$  donde la penúltima desigualdad se debe a que estamos suponiendo que  $(\mathbf{X}_1^t \mathbf{X}_2) = 0$

## 2

### 2.1 Enunciado

Supongamos que  $\mathbf{Y}$  se ajusta a un modelo lineal básico de rango completo, es decir,  $E[\mathbf{Y}] = \mathbf{X}\beta$  y  $Cov[\mathbf{Y}] = \sigma^2 \mathbf{I}_n$  siendo  $\mathbf{X}$  una matriz de orden  $n \times p$  con  $p < n$  y  $r(\mathbf{X}) = p$ . Denotaremos por  $\hat{\beta} = (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{Y}$  al estimador de mínimos cuadrados de  $\beta$ . Si  $\psi = \lambda^t \beta$ ,  $\lambda \in \mathbb{R}$  es una función lineal de  $\delta$ , consideramos el estimador  $\hat{\psi} = \lambda^t \hat{\beta}$ .

- Probar que  $\hat{\psi}$  es un estimador insesgado para  $\psi$  y calcular su varianza
- Demostrar que  $\hat{\psi}$  es el estimador insesgado de mínima varianza de  $\psi$ , en el sentido que si  $T = c^t \mathbf{X}$ ,  $c \in \mathbb{R}^n$  es otro estimador lineal insesgado de  $\psi$ , entonces  $Var[\hat{\psi}] \leq Var[T]$  y se da la igualdad si y solo si  $T = \hat{\psi}$

### 2.2 Respuesta

a)

- $E[\hat{\psi}] = E[\lambda^t \hat{\beta}] = \lambda^t E[\hat{\beta}] = \lambda^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t E[\mathbf{Y}] = \lambda^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{X} \beta = \lambda^t \beta = \psi$
- $Var[\hat{\psi}] = \sum_{i=1}^n Var[\hat{\psi}_i] = tr(Cov[\hat{\psi}]) = tr(Cov[\lambda^t \hat{\beta}]) = tr(\lambda^t Cov[\hat{\beta}] \lambda) =$   
 $tr(\lambda^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t Cov[\mathbf{Y}] ((\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t)^t \lambda) = tr(\lambda^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \sigma^2 \mathbf{I}_n ((\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t)^t \lambda) =$   
 $tr(\lambda^t \sigma^2 (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{X} ((\mathbf{X}^t \mathbf{X})^{-1})^t \lambda) = \sigma^2 tr(\lambda^t (\mathbf{X}^t \mathbf{X})^{-1} \lambda)$

b)

Sea  $T = c^t \mathbf{Y}$  podemos reescribir  $c$  de la forma  $c = (\lambda^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t + b)^t$  entonces para que  $T$  sea insesgado debe de ocurrir que  $\psi = E[T] = E[(\lambda^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t + b)^t \mathbf{Y}] = E[\lambda^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{Y}] + E[b^t \mathbf{Y}] = E[\hat{\psi}] + b^t \mathbf{X} \beta = \psi + b^t \mathbf{X} \beta$  por lo tanto para

que  $T$  sea insesgado debe de ocurrir que  $b\mathbf{X} = 0$ . Teniendo esto en cuenta podemos calcular la matriz de Covarianzas del siguiente modo:  $Cov[T] = c \cdot Cov[Y] \cdot c^t = \sigma^2 \cdot c \cdot c^t = \sigma^2(\lambda^t(\mathbf{X}^t\mathbf{X})^{-1}\mathbf{X}^t + b)(\lambda^t(\mathbf{X}^t\mathbf{X})^{-1}\mathbf{X}^t + b)^t = \sigma^2(\lambda(\mathbf{X}^t\mathbf{X})^{-1}\lambda^t + \lambda^t(\mathbf{X}^t\mathbf{X})^{-1}(b\mathbf{X})^t + b\mathbf{X}\lambda^t(\mathbf{X}^t\mathbf{X})^{-1} + b \cdot b^t) = \sigma^2(\lambda^t(\mathbf{X}^t\mathbf{X})^{-1} + b \cdot b^t)$ . De este modo si  $b = (b_1, \dots, b_n)$  tenemos que:  $ECM(T) = tr(Cov[T]) = \sigma^2 tr(\lambda(\mathbf{X}^t\mathbf{X})^{-1}\lambda^t) + \sigma^2 tr(b \cdot b^t) = ECM(\hat{\psi}) + \sigma^2 \sum_{i=1}^n b_i^2$ . Concluimos que  $ECM(T) \geq ECM(\hat{\psi})$  ( $ECM(\hat{\psi}) = Var[\hat{\psi}] = \sigma^2 tr(\lambda(\mathbf{X}^t\mathbf{X})^{-1}\lambda^t)$  se debe a que  $\psi$  es insesgado y a el apartado a) de este ejercicio) y se dará la igualdad si y solo si  $\sum_{i=1}^n b_i^2 = 0$ , es decir,  $b = 0$

### 3

#### 3.1 Enunciado

Supongamos que  $\mathbf{Y} \sim \mathcal{N}(\mathbf{X}\beta, \sigma^2\mathbf{I}_n)$  donde  $\mathbf{X}$  es una matriz de orden  $n \times p$  ( $p < n$ ) y  $r(\mathbf{X}) = p$ , es decir,  $\mathbf{Y}$  se ajusta a un modelo lineal normal de rango completo. Denotaremos por  $\hat{\beta} = (\mathbf{X}^t\mathbf{X})^{-1}\mathbf{X}^t\mathbf{Y}$ , al estimador de mínimos cuadrados y de máxima verosimilitud de  $\beta$ . Si  $\psi = \lambda^t\beta$ ,  $\lambda \in \mathbb{R}^p$  es una función lineal de  $\beta$ , consideramos el estimador  $\hat{\psi} = \lambda^t\hat{\beta}$ .

- a) Probar que  $\hat{\psi} \sim \mathcal{N}(\psi, \sigma^2\lambda^t(\mathbf{X}^t\mathbf{X})^{-1}\lambda)$
- b) Deducir un intervalo de confianza para  $\psi$  al nivel de confianza  $1 - \alpha$  ( $0 < \alpha < 1$ ).

#### 3.2 Respuesta

a) Primero estudiemos la distribución que sigue  $\hat{\beta}$ , como  $\mathbf{Y} \sim \mathcal{N}(\mathbf{X}\beta, \sigma^2\mathbf{I}_n)$  y  $\hat{\beta}$  es una transformación lineal de  $\mathbf{Y}$ , la distribución resultante también será normal, como esta distribución queda determinada por la media y la varianza basta calcular:

$$E[\hat{\beta}] = (\mathbf{X}^t\mathbf{X})^{-1}\mathbf{X}^t\mathbf{X}\beta = \beta$$

$$Var[\hat{\beta}] = (\mathbf{X}^t\mathbf{X})^{-1}\mathbf{X}^t\sigma^2\mathbf{I}_n\mathbf{X}((\mathbf{X}^t\mathbf{X})^{-1})^t = \sigma^2(\mathbf{X}^t\mathbf{X})^{-1}$$

Por tanto  $\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2(\mathbf{X}^t\mathbf{X})^{-1})$ . Como  $\hat{\psi} = \lambda^t\hat{\beta}$  aplicando el mismo razonamiento calculamos la media y la varianza de  $\hat{\psi}$ :

$$E[\hat{\psi}] = \lambda^t E[\hat{\beta}] = \lambda^t\beta = \psi$$

$$Var[\hat{\psi}] = \sigma^2\lambda^t(\mathbf{X}^t\mathbf{X})^{-1}\lambda = \sigma^2\lambda^t(\mathbf{X}^t\mathbf{X})^{-1}\lambda$$

Y por tanto concluimos que:  $\hat{\psi} \sim \mathcal{N}(\psi, \sigma^2\lambda^t(\mathbf{X}^t\mathbf{X})^{-1}\lambda)$ .

b) Por el apartado anterior sabemos que  $\hat{\psi} \sim \mathcal{N}(\psi, \sigma^2 \lambda^t (\mathbf{X}^t \mathbf{X})^{-1} \lambda)$ . Tipificando obtenemos que

$$\frac{\hat{\psi} - \psi}{\sqrt{\sigma^2 \lambda^t (\mathbf{X}^t \mathbf{X})^{-1} \lambda}} \sim \mathcal{N}(0, 1)$$

Por otro lado, por los apartados b) y c) de la Proposición 7 del Tema 2 sabemos que  $\frac{(n-p)\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-p)$  y dicha variable es independiente de  $\hat{\beta}$  y por lo tanto de cualquier combinación lineal suya, es decir  $\hat{\psi}$ . De todo ello se deduce que

$$\frac{\frac{\hat{\psi} - \psi}{\sqrt{\sigma^2 \lambda^t (\mathbf{X}^t \mathbf{X})^{-1} \lambda}}}{\sqrt{\frac{(n-p)\hat{\sigma}^2}{(n-p)\sigma^2}}} = \frac{\hat{\psi} - \psi}{\sqrt{\hat{\sigma}^2 \lambda^t (\mathbf{X}^t \mathbf{X})^{-1} \lambda}} \sim t(n-p)$$

En consecuencia, si  $t_{n-p, \alpha/2}$  es el cuantil de orden  $1 - \alpha/2$  de la distribución  $t(n-p)$  se verifica que  $P(-t_{n-p, \alpha/2} \leq \frac{\hat{\psi} - \psi}{\sqrt{\hat{\sigma}^2 \lambda^t (\mathbf{X}^t \mathbf{X})^{-1} \lambda}} \leq t_{n-p, \alpha/2}) = 1 - \alpha$ . Despejando  $\psi$  obtenemos que  $P(\hat{\psi} - \sqrt{\hat{\sigma}^2 \lambda^t (\mathbf{X}^t \mathbf{X})^{-1} \lambda} t_{n-p, \alpha/2} \leq \psi \leq \hat{\psi} + \sqrt{\hat{\sigma}^2 \lambda^t (\mathbf{X}^t \mathbf{X})^{-1} \lambda} t_{n-p, \alpha/2}) = 1 - \alpha$  y el ejercicio está completo.

## 4

### 4.1 Enunciado

Para estimar dos parámetros  $\theta$  y  $\Phi$  se realizan observaciones de tres tipos:

- a) m observaciones  $Y_{11}, \dots, Y_{1m}$  con media  $\theta$
- b) m observaciones  $Y_{21}, \dots, Y_{2m}$  con media  $\theta + \Phi$
- c) n observaciones  $Y_{31}, \dots, Y_{3n}$  con media  $\theta - 2\Phi$

Todas las observaciones están sujetas a errores incorrelados de media 0 y tienen varianza  $\sigma^2$ . Hallar los estimadores de mínimos cuadrados de  $\theta$  y  $\Phi$ . Probar que dichos estimadores son incorrelados si y sólo si  $m = 2n$ .

### 4.2 Respuesta

Sabemos que  $E[Y_{1i}] = \theta \forall i \in \{1, \dots, m\}$ ,  $E[Y_{2i}] = \theta + \Phi \forall i \in \{1, \dots, m\}$  y  $E[Y_{3i}] = \theta - 2\Phi \forall i \in \{1, \dots, n\}$ . Construimos el vector  $\mathbf{Y} = (Y_{11}, \dots, Y_{1m}, Y_{21}, \dots, Y_{2m}, Y_{31}, \dots, Y_{3n})$  que nos permite expresar las igualdades anteriores de forma matricial:

$$E[\mathbf{Y}] = \begin{pmatrix} 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ 1 & 1 \\ \vdots & \vdots \\ 1 & 1 \\ 1 & -2 \\ \vdots & \vdots \\ 1 & -2 \end{pmatrix} \begin{pmatrix} \theta \\ \Phi \end{pmatrix} \quad (1)$$

Por otra parte sabemos que existen unos errores  $\varepsilon = (\varepsilon_{11}, \dots, \varepsilon_{1m}, \varepsilon_{21}, \dots, \varepsilon_{2m}, \varepsilon_{31}, \dots, \varepsilon_{3n})$  que cumplen que  $E[\varepsilon] = 0$  y  $Cov[\varepsilon_{ij}, \varepsilon_{tk}] = \sigma^2 \delta_{ij,tk}$ . Como  $r(\mathbf{X}) = 2$  nos encontramos ante un modelo lineal de rango completo donde  $E[\mathbf{Y}] = \mathbf{X}\beta + \varepsilon$

Para obtener el EMC de  $\theta$  y  $\Phi$  basta encontrar el EMC de  $\beta$ . Por la Proposición 1 del Tema 2 sabemos que el EMC de  $\beta$  es de la forma  $\hat{\beta} = (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{Y}$ . Tras realizar los cálculos (los he hecho en sucio) llegamos a que la matriz  $\hat{\beta}$  es de la forma:

$$\begin{pmatrix} \hat{\theta} \\ \hat{\Phi} \end{pmatrix} = \frac{1}{m^2 + 13nm} \begin{pmatrix} (m+4n)\mathbf{Y}_1 + 6n\mathbf{Y}_2 + 3m\mathbf{Y}_3 \\ (-m+2n)\mathbf{Y}_1 + (m+3n)\mathbf{Y}_2 + -5m\mathbf{Y}_3 \end{pmatrix} \quad (2)$$

Donde  $\mathbf{Y}_1 = \sum_{i=1}^m Y_{1i}$ ,  $\mathbf{Y}_2 = \sum_{i=1}^m Y_{2i}$ ,  $\mathbf{Y}_3 = \sum_{i=1}^n Y_{3i}$ .

Además por el apartado a) de la Proposición 1 del Tema 2 sabemos que  $(\hat{\beta}, \hat{\Phi})$  es un estimador insesgado. Veamos que su matriz de covarianzas es diagonal si y solo si  $m = 2n$ :

$$Cov[(\hat{\theta}, \hat{\Phi})] = \begin{pmatrix} Cov[\hat{\theta}] & Cov[\hat{\theta}, \hat{\Phi}] \\ Cov[\hat{\Phi}, \hat{\theta}] & Cov[\hat{\Phi}] \end{pmatrix} \quad (3)$$

Pero también sabemos que

$$Cov[(\hat{\theta}, \hat{\Phi})] = \sigma^2 (\mathbf{X}^t \mathbf{X})^{-1} = \frac{1}{m^2 + 13nm} \begin{pmatrix} m+4n & -m+2n \\ -m+2n & 2m+n \end{pmatrix} \quad (4)$$

Entonces  $Cov[(\hat{\theta}, \hat{\Phi})] = 0 \iff \frac{1}{m^2+13nm}(-m+2n) = 0 \iff -m+2n = 0 \iff m = 2n$  Por lo tanto los estimadores  $\hat{\theta}, \hat{\Phi}$  son insesgados si y solo si  $m = 2n$

## 5

### 5.1 Enunciado

Supongamos que  $\mathbf{Y}$  se ajusta a un modelo lineal básico de rango completo, es decir,  $E[\mathbf{Y}] = \mathbf{X}\beta$  y  $Cov[\mathbf{Y}] = \sigma^2 I_n$  siendo  $\mathbf{X}$  una matriz de orden  $n \times p$

con  $p < n$  y  $r(\mathbf{X}) = p$ . Si definimos el vector *valores ajustados* como  $\hat{\mathbf{Y}} = (\hat{Y}_1, \dots, \hat{Y}_n)^t = \mathbf{X}\hat{\beta}$  y el vector de *residuos* como  $\hat{e} = (e_1, \dots, e_n)^t = \mathbf{Y} - \hat{\mathbf{Y}}$ . Se pide:

- Calcular  $E[\hat{\mathbf{Y}}]$ ,  $Cov[\hat{\mathbf{Y}}]$ ,  $E[\hat{e}]$  y  $Cov[\hat{e}]$
- Probar que  $\sum_{i=1}^n Var[\hat{\mathbf{Y}}_i] = \sigma^2 p$  y que  $\sum_{i=1}^n \hat{\mathbf{Y}}_i e_i = 0$

## 5.2 Respuesta

a)

- $E[\hat{\mathbf{Y}}] = E[\mathbf{X}\hat{\beta}] = \mathbf{X}E[\hat{\beta}] = \mathbf{X}\beta$  donde  $\hat{\beta} = (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{Y}$
- $Cov[\hat{\mathbf{Y}}] = Cov[\mathbf{X}\hat{\beta}] = \mathbf{X}Cov[\hat{\beta}]\mathbf{X}^t = \mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t Cov[\mathbf{Y}]\mathbf{X}^t ((\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t)^t = \sigma^2 \mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t$
- $E[\hat{e}] = E[\mathbf{Y} - \hat{\mathbf{Y}}] = E[\mathbf{Y}] - E[\hat{\mathbf{Y}}] = 0$
- $Cov[\hat{e}] = E[(\hat{e} - E[\hat{e}])(\hat{e} - E[\hat{e}])^t] = E[e e^t] = E[SEC]$  y por la Proposición 4 del Tema 2 sabemos que  $E[SEC] = (n - p)\sigma^2$  por lo tanto  $Cov[\hat{e}] = (n - p)\sigma^2$ .

b)  $\sum_{i=1}^n Var[\hat{\mathbf{Y}}_i] = tr(Cov[\hat{\mathbf{Y}}]) = tr(\sigma^2 \mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t)$  pero por el Lema 3 del Tema 2 sabemos que  $\mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t$  es idempotente:

$$(\mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t)(\mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t)^t = \mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t$$

y ademas es simétrica, por lo tanto por la propiedad d) de las matrices idempotentes del Tema 1 tenemos que  $r(\mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t) = tr(\mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t)$ , por la propiedad b) del rango del Tema 1 sabemos que  $r(\mathbf{X}) = r(\mathbf{X}^t \mathbf{X}) = r((\mathbf{X}^t \mathbf{X})^{-1})$  por otra parte  $\mathbf{X}$  es no singular y por tanto invertible, por la propiedad a) del mismo apartado sabemos que  $r(A) = r(BA) = r(AC)$  con B y C matrices no singulares, por lo tanto como  $r(\mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t) = r(\mathbf{X}) = p$ , concluimos que  $tr(\sigma^2 \mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t) = \sigma^2 tr(\mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t) = \sigma^2 r(\mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t) = \sigma^2 p$

Para demostrar que  $\sum_{i=1}^n \hat{\mathbf{Y}}_i e_i = 0$  debemos de tener en cuenta que  $\hat{\mathbf{Y}} = H\mathbf{Y}$  y que  $\hat{e} = \mathbf{Y} - \hat{\mathbf{Y}} = (\mathbf{I}_n - H)\hat{\mathbf{Y}}$  donde  $H = \mathbf{X}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t$ , como sabemos que  $H$  y  $\mathbf{I}_n - H$  generan subespacios sobre  $\mathbb{R}^n$  ortogonales entre si concluimos que  $(\mathbf{I}_n - H)\hat{\mathbf{Y}}$  y  $H\mathbf{Y}$  son vectores ortogonales.

## 6

### 6.1 Enunciado

Sea  $\mathbf{Y} \sim \mathcal{N}(\mu, \mathbf{V})$

a) Si  $\mathbf{Z} = \mathbf{A}\mathbf{Y} + b$  con  $\mathbf{A}$  matriz  $k \times n$  de rango  $k$  ( $k \leq n$ ) y  $b \in \mathbb{R}^k$ , entonces  $\mathbf{Z} \sim \mathcal{N}(\mathbf{A}\mu + b, \mathbf{A}\mathbf{V}\mathbf{A}^t)$ .

b) Probar que un vector aleatorio  $\mathbf{Y} = (Y_1, \dots, Y_n)^t \sim \mu, \mathbf{V}$  si y solo si para todo  $\lambda \in \mathbb{R}^n$ ,  $\lambda^t \mathbf{Y} \sim \mathcal{N}(\lambda^t \mu, \lambda^t \mathbf{V} \lambda)$

## 6.2 Respuesta

(a partir de ahora la transpuesta será denotada con el símbolo T en vez de t)

a) Sabemos que una v.a sigue una distribución normal cuando su función de momentos es de la forma:  $M_X(t) = \exp(t^T \mu + \frac{1}{2} t^T V t)$  donde  $V$  es la matriz de covarianzas. Por otra parte la función de momentos de una v.a cualquiera es de la forma  $M_R(t) = E[\exp(t^T x)]$ , Veamos que  $\mathbf{Z}$  tiene una función de momentos de la primera forma:

$$M_Z(t) = E[\exp(t^T (\mathbf{A}x + b))] = E[\exp(t^T (\mathbf{A}x)) \exp(t^T b)] = \exp(t^T b) E[\exp(t^T \mathbf{A}x)] = \exp(t^T b) M_Y(\mathbf{A}^T t) = \exp(t^T (\mathbf{A}\mu + b) + \frac{1}{2} t^T \mathbf{A} \mathbf{V} \mathbf{A}^T t)$$

Concluimos que  $\mathbf{Z}$  sigue una distribución normal

b)

$\Rightarrow$

Una v.a también queda determinada por su función característica, en el caso de una v.a con distribución normal, esta es:  $\phi_Y(t) = \exp(it\mu - \frac{1}{2} t^T \mathbf{V} t)$ , por otra parte la función característica de  $\lambda^t \mathbf{Y} = E[\exp(it(\lambda^t \mathbf{Y}))] = E[\exp(i(t\lambda^T) \mathbf{V})] = \exp(i(\lambda t)^T \mu - \frac{1}{2} (\lambda t)^T \mathbf{V} \lambda t) = \exp(it(\lambda^T \mu) - \frac{1}{2} t(\lambda^T \mathbf{V} \lambda)t)$  Por la unicidad de la función característica concluimos que  $\lambda^t \mathbf{Y} \sim \mathcal{N}(\lambda^t \mu, \lambda^t \mathbf{V} \lambda^t)$  Otra forma más cómoda de verlo es reducirnos al caso a), tomando  $b = 0$  y  $k = 1$

$\Leftarrow$

$\phi_Y(\beta) = E[\exp(i\beta^T \mathbf{Y})]$  tomando  $\beta = \lambda t$  tenemos  $= E[\exp(i(t\lambda)^T \mathbf{Y})] = E[\exp(it(\lambda^T \mathbf{Y}))] = \exp(i(\lambda t)^T \mu - \frac{1}{2} (\lambda t)^T \mathbf{V} \lambda t) = \exp(i(\beta)^T \mu - \frac{1}{2} (\beta)^T \mathbf{V} \beta)$  y por la unicidad de la función característica concluimos que  $\mathbf{Y} \sim \mathcal{N}(\mu, \mathbf{V})$ .